Репозиторий
github link

Идея

В этой работе мы проверяем, может ли добавка по оценке большой авторегрессионной vision-language модели (VLM) улучшать семантическое соответствие изображения текстовому запросу в text-to-image генерации диффузионной моделью. Мотивация в том, что современные VLM уже содержат достаточно сильные знания о композиции объектов, отношениях, количествах и редких семантических сочетаниях, а потому их сигнал потенциально можно использовать не только для post оценки, но и непосредственно для управления траекторией генерации.

Идея близка к классическому classifier guidance для диффузионных моделей, но вместо градиента классификатора используется градиент функции соответствия изображения и текста, вычисленный с помощью VLM. Важно, что речь идёт именно о больших авторегрессионных моделях. Так что метрику качества мы будем от них получать, как текстовый ответ на вопрос о соответствии изображения промту : Visual Question Answering (VQA). Далее мы будем называть наш алгоритм или VLM guidance или VQA score пайплайном.

Так же, кроме сильной является мысль о том, что вернормированная семантика изображения (крупные формы, цвета, отношения объектов) задаётся на ранних итерациях денойза. Наш пайплайн нацелен на то, чтобы подтолкнуть траекторию ранних латентов в сторону большего семантического соответствия промту.

Введение в область и обозначения

В стандартной диффузионной генерации изображение получается итеративным денойзингом латентных переменных

$$x_T \to x_{T-1} \to \cdots \to x_0$$

Шаг такого разумечения $x_t \to x_{t-1}$ основывается на предсказании диффузионной модели $\epsilon_\theta(x_t, p, t)$,где x_t - латент, t - номер шага разумечения и p - эмбеддинг промта.

В конце генерации, при получении x_0, происходит отображение x_0 в пространство изображений $I = \mathrm{VAE}(x_0)$

Так же стандартные алгоритмы позволяют по x_t и предсказанному $\epsilon_\theta(x_t)$ например строить оценку $\hat{x}_0^t$ на x_0

Алгоритм

Наш пайплайн строится вокруг $\mathcal{L}_{\text{vqa}}(I)$ - лосса посчитанного на VLM оценке соответствие семантики изображения промту. Мы берем диффузионных этого лосса по латенту $\eta_t \leftarrow \nabla_{x_t}\mathcal{L}_{\text{vqa}}(I)$ и делаем M шагов градиентного спуска по x_t.

Чтобы избежать трудоемкого вычисления градиента сквозь все итерации денойзинга $\nabla_{\lambda}\mathcal{L}_{\text{vqa}}(I)$ мы считаем градиент лосса от оценки на изображение: $\nabla_{\lambda}\mathcal{L}_{\text{vqa}}(\hat{I}_\lambda)$, где $\hat{I}_\lambda = \mathrm{VAE}(\hat{x}_0^\lambda)$

В нашем пайплайне лосс считается по формуле

$$\mathcal{L}_{\text{vqa}}(I) = \mathrm{CE}(\mathrm{VLM}(I, q)[:|Y|], Y)$$

где p - оригинальный промт генерации изображения $q(p)$ - функция оборачивающая промт генерации в вопрос о соответствии изображения промту, $\mathrm{VLM}(I, q)[:|Y|]$ - предсказанное VLM распределение вероятностей на первый токен ответа на вопрос о соответствии изображения промту генерации.

Полученный таким образом градиент нормировался и использовался в градиентном спуске. В общем случае за раз мы делали M шагов градиентного спуска:

$$\lambda_t \leftarrow \lambda_t - \lambda \frac{\nabla_{\lambda}\mathcal{L}_{\text{vqa}}(\hat{I}_\lambda)}{|\nabla_{\lambda}\mathcal{L}_{\text{vqa}}(\hat{I}_\lambda)|}$$

Также гладкие градиентные спуски повторяется первые K итераций разсумечения, что позволяет приблизить семантики ранних латентов к верной семантике промта.

Целиком наш пайплайн можно описать следующим псевдокодом

```
Algorithm. VLM-guided denoising of early latents.
Input: prompt p, initial noise x_T, diffusion model ε_θ, VAE decoder, VLM, hyperparameters
K, M, λ.
Output: generated image I.
For t = T, T−1, …, 1:
  If t > T − K:
    For j = 1, …, M:
      Predict ε_t from x_t using ε_θ(x_t, p, t).
      Decode current image estimate Î_λ = VAE(x̂_0^λ).
      Form question q(p).
      Compute VLM loss L_vqa = CE(VLM(Î_λ, q(p))[:|Y|], Y).
      Compute gradient η_t ← ∇_{x_t} L_vqa.
      Normalize gradient η_t ← η_t / |η_t|.
      Update latent x_t ← x_t − λ η_t.
  Perform ordinary diffusion update x_t → x_{t−1}.
Decode final latent I ← VAE(x_0).
Return I
```

Экспериментальный сетап

В качестве диффузионной модели использовалась stable diffusion 1.5, $T = 30$ итераций денойзинга, $K = 15$.
В качестве VLM использовалась clip-flant5-xxl.
Получение результаты достигались при $K = 10$, $M = 1$, $\lambda = 0.2$

Качественные сравнения

Результаты получились неоднозначные. Есть примеры улучшения соответствия изображения промту, как на Figure 1, слева, vanilla пайплайн не справляется с формированием правильно семантики, тогда как справа наш метод делает генерацию ближе к промту.

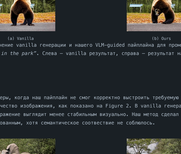

(a) Vanilla (b) Ours

Figure 1: Сравнение vanilla генерации и нашего VLM-guided пайплайна для промта *"A bear does a handstand in the park"*. Слева – vanilla результат, справа – результат нашего метода.

Так же есть примеры, когда наш пайплайн не смог корректно выстроить требуемую семантику, но улучшил общее качество изображения, как показано на Figure 2. В vanilla генерации также нет кролика, а изображение выглядит менее стабильным визуально. Наш метод сделал изображение более структурированным, хотя семантическое соответствие не соблюлось.

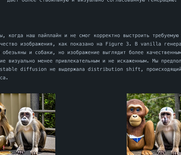

(a) Vanilla (b) Ours

Figure 2: Сравнение vanilla генерации и нашего VLM-guided пайплайна для промта *"an elephant under a rabbit"*. Слева – vanilla результат, справа – результат нашего метода. Несмотря на то, что требуемая семантика *"elephant under a rabbit"* не воспроизводится полностью, наш пайплайн дал более стабильную и визуально согласованную генерацию.

Но есть и примеры, когда наш пайплайн и не смог корректно выстроить требуемую семантику и ухудшил общее качество изображения, как показано на Figure 3. В vanilla генерации также две обезьяны, вместе обезьяны и собака, но изображение выглядит более качественным. Наш метод сделал изображение визуально менее привлекательным и не исхаженным. Мы предполагаем что это из-за того, что stable diffusion не выдержала distribution shift, происходящий при наших итерациях градиента.

(a) Vanilla (b) Ours

Figure 3: Сравнение vanilla генерации и нашего VLM-guided пайплайна для промта *"a dog and a monkey"*. Слева – vanilla результат, справа – результат нашего метода. Требуемая семантика "a dog and a monkey" не воспроизводится ни одним из пайплайнов, но как несколько ухудшил визуальное качество изображения.

Количественные сравнения

Мы провели сравнения по метрикам трех пайплайнов генерации. Vanilla – оригинальный пайплайн stable diffusion 1.5, VQA score – предложенный нами пайплайн и генерация Flux1-dev – значительно более сильной моделью чем stable diffusion 1.5

Количественные результаты также получились неоднозначными. Чтобы понять, как guidance влияет не только на отдельные примеры, но и на распределение качества по датасету, мы сравнили пайплайны по нескольким метрикам: Alignment Score, Quality Score и CLIP Score. Соответствующие распределения показаны на Figure 4, Figure 5 и Figure 6.

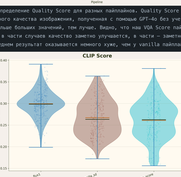

Figure 4: Распределение Alignment Score для разных пайплайнов. Alignment Score вычислялся как оценка соответствия семантики изображения исходному промту, полученная с помощью GPT-4o. Чем больше больших значений, тем лучше. Видно, что для нашего VQA Score пайплайна значения метрики в диапазоне 68–88 встречается реже, чем для vanilla пайплайна.

Figure 5: Распределение Quality Score для разных пайплайнов. Quality Score вычислялся как оценка визуального качества изображения, полученная с помощью GPT-4o без учета соответствия промту. Чем больше больших значений, тем лучше. Видно, что наш VQA Score пайплайн расширяет распределение: в части случаев качество заметно улучшается, в части – заметно ухудшается. В среднем результат оказывается немного хуже, чем у vanilla пайплайна.

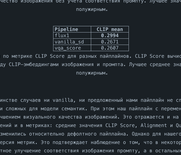

Figure 6: Распределение CLIP Score для разных пайплайнов. CLIP Score вычислялся как cosine similarity между CLIP-эмбеддингом изображения и промта. Чем больше больших значений, тем лучше. Видно, что наш пайплайн расширяет диапазон значений метрики в обе стороны по сравнению с vanilla пайплайном, при этом среднее значение остается примерно на том же уровне.

Средние значения метрик для разных пайплайнов приведены в таблицах Table 1, Table 2 и Table 3.

Pipeline	Alignment mean
flux1	94.565
vanilla_cd	95.017
vqa_score	94.148

Table 1: Сводка по метрике Alignment Score для разных пайплайнов. Alignment Score отражает соответствие семантики изображения текстовому промту. Лучшее значение выделено полужирным.

Pipeline	Quality mean
flux1	89.929
vanilla_cd	89.443
vqa_score	83.765

Table 2: Сводка по метрике Quality Score для разных пайплайнов. Quality Score отражает визуальное качество изображения без учета соответствия промту. Лучшее значение выделено полужирным.

Pipeline	CLIP mean
flux1	0.2984
vanilla_cd	0.2617
vqa_score	0.2681

Table 3: Сводка по метрике CLIP Score для разных пайплайнов. CLIP Score вычислялся как cosine similarity между CLIP-эмбеддингом изображения и промта. Лучшее среднее значение выделено полужирным.

В целом, в большинстве случаев не vanilla, но предложенный нами пайплайн не справились с задачей генерации сложных для модели семантик. При этом наш пайплайн с переменным успехом справился с улучшением визуального качества изображений. Это отражается и на приведенных примерах изображений и в метриках. Среднее значение CLIP Score, Alignment и Quality практически не изменилось относительно дефолтного пайплайна. Однако для нашего метода немного увеличилась дисперсия метрик. Это подтверждает наблюдение о том, что в некоторых сценариях наблюдается заметное улучшение соответствия изображения промту, в в остальных сценариях примерно равнонерозтно метрики либо немного лучше, либо немного хуже.

Вывод и планы

И того, наш пайплайн в каких-то случаях успешно формирует в изображении семантики промта, в остальных не справляется с задачей и несколько улучшает или ухудшает качество изображения. Мы предполагаем, что такое поведение обусловливается недостаточной степенью влияния на ход генерации и при этом портраимной величиной distribution shift для диффузионной модели, возникающим при нашем гайдинге.

Сейчас получается не выразительный результат, но несколько список мест, которые надо в нашем пайплайне исследовать, чтобы определить, как усилить гайдинг или убедиться, что он не применим к нашей задаче. А именно надо

- Изучить информативность VLM оценки
- Рассмотреть норм шагов гайдинга и денойзинга