

Введение

В прошлом спринте мы сделали несколько sanity checks разных мест нашего guided пайплайна генерации, а так же провели небольшой ablation studies, определившись с тем, какую из использованных vlm стоит использовать, какой из рассмотренных vlm лоссов себя лучше показывает, а так же заметили что vlm guided генерация иногда становится заметно лучше, если сообщать vlm модели, что она оценивает недогенерированную шумную версию картинки. Прошлый спринт мы закончили на том, что, несмотря на то, что наш пайплайн показал себя лучшей бейзлайна, мы получили довольно маленький прирост ключевой метрики. Мы решили сделать три действия:

- 1. Мы решили заменить слабую stable diffusion 1.5 на более сильный FLUX 1 dev. Идея была в том, что наш пайплайн в целом заточен под небольшую корректировку изображения в сторону улучшения метрики, так что вытянуть плохое sd1.5 изображение (совсем не похоже на требуемое) у нас и не может получиться.
- 2. Мы не нашли оптимальные значения гиперпарметров гайденса – надо сделать более качественный grid search, чтобы выжать из нашего подхода максимум
- 3. Глазами оценить прирост качества генерации от нашего пайплайна, поскольку возможно выбранная нами метрика не идеально коррелирует с тем, какая метрика нам нужна.

В двух словах напомним как работает наш пайплайн генерации. Его схема приведена на Figure 1. В обычные итерации диффузионного расшумления мы добавляем guidance итерации – подкручиваем латент в сторону увеличения метрики сходства изображения промпту. Наша идея очень похожа на classifier guidance, но вместо ограниченного классификатора мы используем робастную vlm модель (Qwen2.5-VL-3B-Instruct). Мы показываем ей промежуточную картинку с вопросом о ее сходстве промпту генерации. По первому токenu ее ответа мы строим лосс – метрику сходства изображения промпту:  $\mathcal{L}_{vlm} = -\log(\sigma(p("Yes") - p("No")))$ , где  $p(token)$  – вероятность текстового токена при генерации ответа на вопрос о сходстве промпта и изображения. На предыдущие спринты показали, что guidance шаги вносят значительные корректировки в крупные семантики изображения лишь на ранних этапах, так что гайденс мы делаем на первых 15 (из 30) таймстепах. Для этих guided вмешательств в ход генерации мы выделили три гиперпараметра:

- 1. lr: float – коэффициент для градиента ( $\eta$  на схеме)
- 2. iter: int – кол-во итераций гайденса
- 3. noise\_info: bool – есть ли в vlm промпте информация о том, что ей показывают мутную недогенерированную версию картинку.




Figure 1:  
Схема нашего guided пайплайна генерации изображений.

Grid search

Теперь рассмотрим наш поиск оптимальных lr, iter и noise\_info.

Рассмотренные нами сочетания iter x lr приведены в таблице Table 1. Для iter 1–8 мы так же перебрали True, False значения noise\_info.

| iter \ lr | 0.5 | 1 | 2 | 4 | 8 |
|-----------|-----|---|---|---|---|
| 1         | ✓   | ✓ | ✓ | ✓ | ✓ |
| 2         | ✓   | ✓ | ✓ | ✓ | ✓ |
| 4         | ✓   | ✓ | ✓ | ✓ | ✓ |
| 8         | ✓   | ✓ | ✓ | ✓ | ✓ |
| 12        | ✓   | ✓ | ✗ | ✗ | ✗ |

Table 1:  
Рассмотренные сочетания гиперпараметров iter и lr.

Каждым из пайплайнов мы сгенерировали изображения по первым 50 промптам из датасета whoops (link). Далее сгенерированные изображения мы оценили по llm as a judge метрикам alignment и quality. Alignment – это оценка качества соответствия изображения промпту в диапазоне от 1 до 5, где 1 обозначает что изображение совсем не соответствует запросу, а 5 – что изображение полностью передаёт смысл запроса, все элементы корректны. Quality – оценка визуальной целостности изображения вне зависимости от промпта, где 1 обозначает что изображение содержит серьёзные ошибки рендеринга, бессмысленно или повреждено, а 5 – что оно чисто, реалистично и полностью согласовано – без видимых дефектов. Обе метрики чем больше тем лучше

Для каждого сочетания гиперпараметров мы рассчитали средние значения alignment и quality. Общее распределение наших запусков в осях quality/alignment приведено на изображении Figure 2.





Figure 2:  
Все наши запуски в осях quality/alignment

Во-первых отметим, что FLUX 1 dev baseline имеет alignment 3.66. Это то значение, до которого мы смогли поднять качество генерации на sd1.5 в прошлом спринте. Таким образом базово flux пайплайн более сильный, как и ожидалось

Во-вторых отметим, что, как и для sd1.5, наш пайплайн, как правило, дает прирост ключевой метрики (alignment)

Так же констатируем, что наш лучший запуск дал alignment 3.88. Вообще это не то, чего мы бы хотели от нашей идеи. Прирост мы дали, идея не бессмысленна, но прирост не значителен.

Определим, можно ли ожидать от нашего пайплайна значительно лучших результатов при других сочетаниях lr, iter и noise\_info. На Figure 3 приведены значения alignment при рассмотренных значениях lr, iter. Как видно, и для noise\_info = True и для noise\_info = False мы покрыли локальный максимум нашим grid search. Так же отмечу, что не думаю, что grid search с более мелким шагом позволил бы нам найти значительно более высокий пик, поскольку, по опыту, не значительные увеличения или уменьшения количества гайденса, так же не значительные влияют на финальное изображение.



Таким образом, мы можем считать, что нашли близкие к оптимальным гиперпараметры. Из текущей реализации guided генерации мы не получим значимо лучших результатов, увы.

Human evaluation

Мы хотели оценить, насколько на самом деле качественный прирост дает наш пайплайн генерации. Для этого мы рассмотрели по 50 генераций baseline (FLUX 1 dev) и нашим лучшим guided (iter = 8, lr = 1) пайплайном. С файлом, по которому мы подсчитывали метрику вы можете ознакомиться по ссылке (link) – мы подчеркнули примеры удачной генерации. Для baseline пайплайна таких примеров получилось 30/50, для нашего – 36/50. Где-то лучше получилось у бейзлайна, где-то – у нас, а в целом мы увеличили количество удачных генераций на 20% – не так уж и плохо. Примеры генераций нашим и baseline пайплайнами Table 2.




Table 2:  
Прямое сравнение baseline и ours (guided) генераций.

Отмечу, что вопреки нашим ожиданиям, guided генерации зачастую сильно отличались от vanilla. Несмотря на то, что мы только вмешиваемся в генерацию, мы успешно меняем крупные объекты, формы, ракурсы.

Выводы

Наша идея vlm guided генерации, хоть и оказалась в валидной, но не позволила улучшить соответствие изображения промпту настолько, насколько этого хотелось бы и текущими методами мы не сможем достаточно сильно вытянуть наш пайплайн.