Репозиторий

github link

Идея

В этой работе мы проверяли, может ли guidance по оценке большой авторегрессионной vision-language модели (VLM) улучшать семантическое соответствие изображения текстовому запросу в text-to-image генерации диффузионной моделью. Мотивация в том, что современные VLM уже содержат достаточно сильные знания о композиции объектов, отношениях, количествах и редких семантических сочетаниях, а потому их сигнал потенциально можно использовать не только для post оценки, но и непосредственно для управления траекторией генерации.

Идея близка к классическому classifier guidance для диффузионных моделей, но вместо градиента классификатора используется градиент функции соответствия изображения и текста, вычисленный с помощью VLM. Важно, что речь идет именно о больших авторегрессивных моделях. Так что метрику качества мы будем от них получать, как текстовый ответ на вопрос о соответствии изображения промпту — Visual Question Answering (VQA). Далее мы будем называть наш алгоритм или LLM guidance или VQA score пайплайном.

Так же, изначульной является мысль о том, что верхнеуровневая семантика изображения (крупные формы, цвета, отношения объектов) задается на ранних итерациях денойза. Наш пайплайн надеется на то, чтобы подтолкнуть генерацию ранних латентов в сторону большего семантического соответствия промпту.

Введение в область и обозначения

В стандартной диффузионной генерации изображение получается в итеративным денойзингом латентных переменных

$$z_T \to z_{T-1} \to \dots \to z_0$$

Шаги такого разуччения $z_t \to z_{t-1}$ основывается на предсказании диффузионной модели $\varepsilon_\theta(z_t, t, p)$, где z_t — латент, t — номер шага разшумления и p — эмбеддинг промпта.

В конце генерации, при получении z_0, происходит отображение z_0 в пространство изображений

$$I = \mathrm{VAE}(z_0)$$

Так же стандартные алгоритмы позволяют по z_t и предсказанному $\varepsilon_\theta(z_t)$ напрямую строить оценку $\hat{z}_0^t$ на z_0

Алгоритм

Наш пайплайн строится вокруг $\mathcal{L}_{\mathrm{vqa}}(I)$ — лосса построенного на VLM оценке соответствия семантики изображения промпту. Мы берем дифференциал этого лосса по латенту z_t: $\nabla_{z_t}\mathcal{L}_{\mathrm{vqa}}(I)$ и делаем M шагов градиентного спуска по z_t.

Чтобы избежать трудоемкого вычисления градиента сквозь все итерации денойзинга $\nabla_{z_t}\mathcal{L}_{\mathrm{vqa}}(I)$ мы считаем градиент лосса от оценки на изображение: $\nabla_{z_t}\mathcal{L}_{\mathrm{vqa}}(\hat{I}_t)$, где $\hat{I}_t = \mathrm{VAE}(\hat{z}_0^t)$

В нашем пайплайне лосс считался по формуле

$$\mathcal{L}_{\mathrm{vqa}}(I) = \mathrm{CE}(\mathrm{VLM}(I, q(p)), Y_{\mathrm{no}})$$

где p — оригинальный промпт генерации изображения $q(p)$ — функция оборачивающая промпт генерации в вопрос о соответствии изображения промпту, $\mathrm{VLM}(I, q(p))$ — предсказанное VLM распределение вероятностей на первый токен ответа на вопрос о соответствии изображения промпту генерации.

Полученный таким образом градиент нормировался и использовался в градиентном спуске. В общем случае за раз мы делали M шагов градиентного спуска:

$$\hat{z}_t \leftarrow \hat{z}_t - \lambda \frac{\nabla_{\hat{z}_t}\mathcal{L}_{\mathrm{vqa}}(\hat{I}_t)}{\|\nabla_{\hat{z}_t}\mathcal{L}_{\mathrm{vqa}}(\hat{I}_t)\|}$$

Также гайденс градиентные спуски повторяется перед итерацией K итераций расшумления, что позволяет приблизить семантики ранних латентов к верной семантике промпта.

Целиком наш пайплайн можно описать следующим псевдокодом

Algorithm. VLM-guided denoising of early latents.
Input: prompt p, initial noise z_T, diffusion model ε_θ, VAE decoder, VLM, hyperparameters K, M, λ.
Output: generated image I.

```
For t = T, T − 1, ..., 1:
  If t > T − K:
    For j = 1 ... M:
      Predict ẑ_0^t from z_t using ε_θ(z_t, t, p).
      Decode current image estimate: Î_t = VAE(ẑ_0^t).
      Form question q(p).
      Compute VLM loss L_vqa = CE(VLM(Î_t, q(p)), Y_no).
      Compute gradient g_t = ∇_{z_t} L_vqa.
      Normalize gradient g_t ← g_t / ||g_t||.
      Update latent z_t ← z_t − λ g_t.
  Perform ordinary diffusion update z_t → z_{t−1}.
Decode final latent: I = VAE(z_0).
Return I
```

Экспериментальный сетап

В качестве диффузионной модели использовалась stable diffusion 1.5, $T = 30$ итераций денойзинга, $w_{\mathrm{cfg}} = 7.5$.
В качестве VLM использовалась clip-flant5-xxl.
Получение результата достигалось при $K = 10$, $M = 2$, $\lambda = 0.2$

Качественные сравнения

Результаты получились неоднозначные. Есть примеры улучшения соответствия изображения промпту, как на Figure 1, слева, vanilla пайплайн не справляется с формированием правильно семантики, тогда как справа наш метод делает генерацию ближе к промпту.

(a) Vanilla (b) Ours

Figure 1: Сравнение vanilla генерации и нашего VLM-guided пайплайна для промпта *"A bear does a handstand in the park"*. Слева — vanilla результат, справа — результат нашего метода.

Так же есть примеры, когда наш пайплайн не смог корректно выстроить требуемую семантику, но улучшил общее качество изображения, как показано на Figure 2. В vanilla генерации также нет кролика, но изображение выглядит менее стабильным визуально. Наш метод сделал изображение более структурированным, хотя семантическое соответствие не соблюлось.

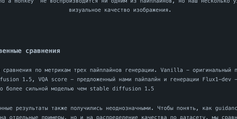

(a) Vanilla (b) Ours

Figure 2: Сравнение vanilla генерации и нашего VLM-guided пайплайна для промпта *"an elephant under a rabbit"*. Слева — vanilla результат, справа — результат нашего метода. Несмотря на то, что требуемая семантика "elephant under a rabbit" не воспроизводится полностью, наш пайплайн дает более стабильную и визульно согласованную генерацию.

Но есть и примеры, когда наш пайплайн и не смог корректно выстроить требуемую семантику и ухудшил общее качество изображения, как показано на Figure 3. В vanilla генерации также две обезьяны, вместо обезьяны и собаки, но изображение выглядит более качественным. Наш метод сделал изображение визуально менее привлекательным и не исхаженным. Мы предпологаем что это из-за того, что stable diffusion не выдержала distribution shift, происходящий при наших итерациях гайденса.

(a) Vanilla (b) Ours

Figure 3: Сравнение vanilla генерации и нашего VLM-guided пайплайна для промпта *"a dog and a monkey"*. Слева — vanilla результат, справа — результат нашего метода. Требуемая семантика "a dog and a monkey" не воспроизводится ни одним из пайплайнов, но наш несколько ухудшил визульную качество изображения.

Количественные сравнения

Мы провели сравнение по метрикам трех пайплайнов генерации. Vanilla — оригинальный пайплайн stable diffusion 1.5, VQA score — предложенный нами пайплайн и генерации Flux1-dev — значительно более сильной моделью чем stable diffusion 1.5

Количественные результаты также получились неоднозначными. Чтобы понять, как guidance влияет не только на отдельные примеры, но и на распределение качества по датасету, мы сравнили пайплайны по нескольким метрикам: Alignment Score, Quality Score и CLIP Score. Соответствующие распределения показаны на Figure 4, Figure 5 и Figure 6.

Figure 4: Распределение Alignment Score для разных пайплайнов. Alignment Score вычислялся как оценка соответствия семантики изображения исходному промпту, полученная с помощью GPT-4o. Чем больше больших значений, тем лучше. Видно, что для нашего VQA Score пайплайна значения метрики в диапазоне 60–80 встречаются реже, чем для vanilla пайплайна.

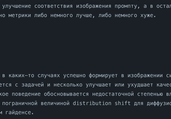

Figure 5: Распределение Quality Score для разных пайплайнов. Quality Score вычислялся как оценка визульного качества изображений, полученная с помощью GPT-4o без учета соответствия промпту. Чем больше больших значений, тем лучше. Видно, что оба VQA Score пайплайн расширяет распределение: в части случаев качество заметно улучшается, в части — заметно ухудшается. В среднем результат оказывается немного хуже, чем у vanilla пайплайна.

Figure 6: Распределение CLIP Score для разных пайплайнов. CLIP Score вычислялся как cosine similarity между CLIP-эмбеддингами изображения и промпта. Чем больше больших значений, тем лучше. Видно, что наш пайплайн расширяет диапазон значений метрики в обе стороны по сравнению с vanilla пайплайном, при этом среднее значение остается примерно на том же уровне.

В целом, в большинстве случаев на vanilla, на предложенный нами пайплайн не справились с задачей генерации сложных для модели семантик. При этом над пайплайн с переменным успехом справился с улучшением визульного качества изображений. Это отражается и на приведенных примерах изображений и в метриках: среднее значение CLIP Score, Alignment и Quality практически не изменилось относительно дефолтного пайплайна. Однако для нашего метода немного увеличилась дисперсия метрик. Это подтверждает наблюдение о том, что в некоторых сценариях наблюдается заметное улучшение соответствия изображения промпту, в в остальных сценариях примерно равновероято метрики либо немного лучше, либо немного хуже.

Вывод и планы

И того, наш пайплайн в каких-то случаях успешно формирует в изображении семантики промта, в остальных не справляется с задачей и несколько улучшает или ухудшает качество изображения. Мы предполагаем, что такое поведение обусловливается недостаточной степенью влияния на ход генерации и при росном пограничной величиной distribution shift для диффузионной модели, возникающим при наших гайденсах.

Мы предполагаем, что если взять более робастную диффузионку модель, то она окажется менее чувствительной к distribution shift, что позволит, усилив степень гайденса, получить более выразительные результаты.

В планирую запустить этот пайплайн гайденса на flux1-dev. По метрикам она себя зарекомендовала как значительно более робастная чем stable diffusion 1.5.